SELF-02 · PYTHON 与 AI 基础

机器学习基础

Machine Learning Foundations

南京财经《机器学习》MOOC · 第9-12周 · Python 语言程序设计（嵩天）+ 黑马 Python+AI

CONCEPT MAP · 概念拆解

本课在回答：理解监督/无监督学习与模型流程。

① 直觉视频 ② 教材定义 ③ 例题拆解 ④ 独立做题 ⑤ 错题复述

建议先看：机器学习 · 南京财经大学 · MOOC

本课学习目标

- [ ] 区分监督学习与无监督学习
- [ ] 理解特征、标签与训练测试划分
- [ ] 会用 sklearn 完成一个分类流水线

本课思维导图

LESSON PY-5

机器学习基础

Machine Learning Foundations

第9-12周 · Python 语言程序设计（嵩天）+ 黑马 Python+AI

01 G 学习目标

- 区分监督学习与无监督学习
- 理解特征、标签与训练测试划分
- 会用 sklearn 完成一个分类流水线

02 C 核心概念

- 特征与标签
- 训练/验证/测试集
- 线性回归
- 逻辑回归与分类
- 决策树与集成

03 F 公式与要点

- 机器学习任务：X（特征） → y（标签）
- 训练与测试：train_test_split(X, y, test_size=0.2)
- 模型与流水线：pipe.fit(X_train, y_train)
- 评估指标：accuracy = 正确数/总数

04 W 易错点

- 数据泄漏：预处理必须只使用训练集信息
- 类别不平衡不能只看准确率
- 特征尺度差异大影响距离类模型
- 测试集只能使用一次

05 E 高频考点

- 线性回归实现
- 分类模型评估
- 过拟合诊断

06 R 资源

- scikit-learn 官方教程 · 快速入门（scikit-learn）
- 机器学习 · 南京财经大学（MOOC）
- 教材：南京财经《机器学习》MOOC

课本概念精要

机器学习任务

监督学习从带标签样本学习映射，无监督学习发现数据内在结构；分类、回归、聚类是三类基本任务。

X（特征）→ y（标签）

训练与测试

数据划分为训练集与测试集，模型只在训练集上学，用测试集评估泛化能力。

```
train_test_split(X, y, test_size=0.2)
```

模型与流水线

sklearn 统一接口 fit(X, y) / predict(X)，Pipeline 把预处理与模型串成一步。

```
pipe.fit(X_train, y_train)
```

评估指标

分类用准确率、精确率、召回率与 F1，回归用均方误差；指标选择取决于问题。

accuracy = 正确数/总数

课本原文要点

机器学习的本质是从数据中学习规律，但评估只能在它没见过的测试数据上进行才有意义。

按南京财经《机器学习》MOOC 与 scikit-learn 官方教程原意整理

核心知识点

- 特征与标签
- 训练/验证/测试集
- 线性回归
- 逻辑回归与分类
- 决策树与集成
- 过拟合与正则化
- 模型评估指标

易错点

- ! 数据泄漏：预处理必须只使用训练集信息
- ! 类别不平衡不能只看准确率
- ! 特征尺度差异大影响距离类模型
- ! 测试集只能使用一次

高频考点

线性回归实现 | 分类模型评估 | 过拟合诊断

典型例题

为什么模型要在训练集上 fit，在测试集上预测?

1. 训练集用于学习参数;
2. 测试集模拟未来新数据;
3. 避免用评估数据参与学习造成过拟合假象。

> **解答**
>
> 答案：只有用未见数据评估，才能反映真实泛化能力。

本课在线课件

scikit-learn 官方教程 · 快速入门

数据集划分、特征与模型训练官方教程

`scikit-learn`

本课视频

机器学习 · 南京财经大学

MOOC

`MOOC`

Andrew Ng Machine Learning

Coursera

`Coursera`

学习自查清单

- [ ] 能区分监督与无监督任务
- [ ] 会划分训练测试集
- [ ] 能调用一个 sklearn 分类器
- [ ] 会解释准确率与过拟合

随堂练习

先独立完成，再翻到下一页核对答案。每道题都写下你的计算过程和选答理由。

1. type([]) 的结果是?

A tuple
B list
C dict
D set

2. len("hello") = ?

A 4
B 5
C 6
D 报错

3. [1,2,3][-1] = ?

A 1
B 2
C 3
D IndexError

4. np.array([1,2,3]) + 1 = ?

A [2,3,4]
B [1,2,3,1]
C 报错
D None

5. df.head() 默认返回前几行?

A 3
B 5
C 10
D 全部

6. 下列哪个属于监督学习?

A K-means 聚类

B 线性回归

C PCA 降维

D 关联规则

参考答案与解析

1. 答案 B

[] 创建 list。

2. 答案 B

字符串 hello 有 5 个字符。

3. 答案 C

负索引 -1 表示最后一个元素。

4. 答案 A

NumPy 广播：每个元素加 1。

5. 答案 B

head() 默认返回前 5 行。

6. 答案 B

线性回归使用带标签数据训练，属于监督学习。

课程配套视频库

黑马程序员 Python + AI 零基础全套
语法、数据分析、AI 应用全覆盖
Bilibili

黑马 Python 8 天入门到精通
快速建立代码手感
Bilibili

CS50 计算机科学导论
编程思维与基础
YouTube

Kaggle Learn
Python、Pandas、ML 动手练习
Kaggle

建议练习与在线题库

教材任务：完成 南京财经《机器学习》MOOC 对应章节的课后 Review Exercises 与奇数题；每周再选 1 个 Problem Set 限时完成。

w3resource Python Exercises
基础语法分主题题库
链接

LeetCode Problem Set
算法与代码手感
链接

Kaggle Learn
Python、Pandas 与 ML 练习
链接

Python语言程序设计 · 嵩天
MOOC 配套编程任务
链接

机器学习 · 南京财经大学
中文 ML 入门
链接

PyTorch 官方教程
官方动手练习
链接